



APRENDIZAJE AUTOMÁTICO

Samuel Hernández Guerrero DAM2



ÍNDICE

1. Introducción
2. Glosario
3. Estado de la cuestión
 - o Breve historia del aprendizaje automático
 - o Situación actual
 - o Tipos de aprendizaje automático
 - o Modelos clásicos
 - o Redes de neuronas
 - o Aprendizaje profundo
 - o Aprendizaje por refuerzo
4. Conclusiones
5. Bibliografía

Introducción

El aprendizaje automático, o machine learning, es una rama de la inteligencia artificial que busca que las máquinas aprendan de datos y experiencias sin necesidad de ser programadas de forma explícita. En este trabajo vamos a recorrer su historia, ver cómo está hoy en día, conocer sus principales tipos y modelos, y explorar tanto las redes neuronales como el aprendizaje profundo y el aprendizaje por refuerzo. La idea es tener una visión completa pero amena del tema.

Glosario

- Algoritmo: conjunto de pasos para resolver un problema.
- Dataset: colección de datos usada para entrenar modelos.
- Overfitting: cuando un modelo se ajusta demasiado a los datos de entrenamiento y falla en datos nuevos.
- Neuronas artificiales: unidades básicas de las redes neuronales.
- Backpropagation: método para ajustar los pesos en una red neuronal.
- CNN/RNN: arquitecturas de redes profundas para imágenes y secuencias.
- Q-Learning: técnica de aprendizaje por refuerzo basada en valores de acción.

Estado de la cuestión

Breve historia

El aprendizaje automático empezó a tomar forma en los años 50 y 60, con el perceptrón como uno de los primeros modelos. En los 80 se popularizó el algoritmo de retropropagación y, desde los 2000, el aumento de datos y potencia de cómputo disparó el desarrollo de redes profundas.

Situación actual

Hoy el *machine learning* está en todas partes: desde buscadores y redes sociales hasta coches autónomos y sistemas médicos. Se combina con grandes volúmenes de datos y hardware especializado (GPUs, TPUs) para lograr resultados sorprendentes.

Tipos de aprendizaje automático

- Supervisado: se entrena con ejemplos que ya tienen la respuesta (por ejemplo, clasificar correos en “spam” o “no spam”).
- No supervisado: busca patrones sin etiquetas, como agrupar clientes por comportamiento.
- Por refuerzo: un agente aprende a tomar decisiones en un entorno recibiendo recompensas o castigos.

Modelos clásicos

- Regresión: predice valores numéricos.
- Árboles de decisión y Random Forest: clasifican datos con reglas en forma de árbol.

- SVM (máquinas de vectores de soporte): separan datos con hiperplanos.
- Clustering (K-Means, DBSCAN): agrupan datos según similitudes.

Redes de neuronas

- Neuronas artificiales: imitan el funcionamiento de una neurona biológica con entradas, pesos y una salida.
- Perceptrón: modelo lineal para clasificación binaria.
- Adaline: similar al perceptrón, pero usa la regla delta para ajustar pesos.
- Perceptrón multicapa (MLP): varias capas de neuronas conectadas, entrenadas con backpropagation.
- Funciones de activación: como la sigmoide, ReLU o tanh, que permiten introducir no linealidad.

Aprendizaje profundo

- Redes profundas: muchas capas que permiten aprender representaciones complejas.
- CNN: ideales para visión artificial.
- RNN, LSTM y GRU: pensadas para secuencias como texto o audio.
- Transformers y modelos fundacionales: revolucionaron el procesamiento de lenguaje natural (ejemplo: ChatGPT).
- IA generativa: crea texto, imágenes, música o código a partir de datos.

Aprendizaje por refuerzo

- Agentes, entornos y recompensas: el agente interactúa con un entorno y recibe feedback.
- Exploración vs explotación: decidir entre probar cosas nuevas o usar lo que ya funciona.
- Q-Learning: aprende valores de acción para maximizar recompensas.
- Deep Reinforcement Learning: combina redes profundas con refuerzo.
- Aplicaciones en robótica: robots móviles, drones, brazos robóticos y robots colaborativos. Se relaciona con arquitecturas que mezclan comportamientos reactivos y deliberativos.

Conclusiones

El aprendizaje automático ha pasado de ser una idea teórica a convertirse en una tecnología que cambia industrias enteras. Su evolución muestra cómo la combinación de datos, algoritmos y potencia de cálculo puede dar lugar a sistemas capaces de aprender y adaptarse. La enseñanza principal es que estamos ante un campo en constante movimiento, con aplicaciones prácticas que van desde lo cotidiano hasta lo futurista.

Bibliografía

- Mitchell, T. (1997). Machine Learning. McGraw-Hill.
- Goodfellow, I., Bengio, Y., & Courville, A. (2016). Deep Learning. MIT Press.
- Russell, S., & Norvig, P. (2021). Artificial Intelligence: A Modern Approach. Pearson.
- Sitios web: Towards Data Science, Medium, Wikipedia, blogs de Google AI y OpenAI.